

REPORTE DE EXPERIENCIA DE INVESTIGACIÓN

Semana 5 (11 de marzo al 15 de marzo 2024)

Jaime Rangel Ojeda
zS22000513@estudiantes.uv.mx

Maestría en Inteligencia Artificial

IIIA Instituto de Investigaciones en Inteligencia Artificial
Universidad Veracruzana
Campus Sur, Calle Paseo Lote II, Sección 2a, No 112
Nuevo Xalapa, Xalapa, Ver., México 91097

22 de marzo de 2024

1. Introducción

La semana cinco consiste en el entrenamiento de la red neuronal y ajuste de hiperparámetros para obtener los mejores resultados. Para la calibración de hiperparámetros se obtuvo el siguiente libro, el cual explica a detalle que importancia tienen los diferentes parámetros durante el entrenamiento del modelo

2. Descripción del objetivo

Lograr una correcta segmentación de los espermatozoides mediante el entrenamiento del modelo, así como almacenar el modelo entrenado para realizar pruebas con nuevas imágenes de entrada.

3. Descripción de actividades

3.1. Lectura de la base de datos

Esta es una descripción breve de la base de datos:

- El modelo fue entrenado para imágenes con una resolución de 256 x 256 píxeles en una composición de colores RGB con 3 canales.
- El total de imágenes en la base de datos es de 1,203 con sus respectivas máscaras binarias.
- Las imágenes de entrada se convirtieron a formato JPEG.
- Las máscaras binarias se convirtieron a formato PNG.
- La resolución original de la base de datos es de 1832 x 1372 píxeles en una composición de colores RGB.

3.2. Ajuste de hiperparámetros

- **epoch:** También conocido como iteración de entrenamiento, es cuando un modelo completa un ciclo y ve todo el conjunto de entrenamiento. Cuantas más iteraciones, más características de nuestros datos de entrenamiento aprende el modelo.

En las pruebas se encontró que **50** épocas son suficientes para que el modelo aprenda las características de la base de datos de espermatozoides.

- **batch_size:** Especifica el número de muestras durante el procesamiento.

Se encontró que arriba de **16** el entrenamiento tiende a empeorar para poder segmentar correctamente, por lo que se dejó en ese valor.

- **patience:** Número de épocas sin mejora después de las cuales el entrenamiento se detendrá.

Se decidió definir este parámetro como **15** épocas, ya que con este valor es suficiente para detectar que al alcanzar 15 épocas sin mejora es mejor detener el entrenamiento.

- **learning_rate:** La tasa de aprendizaje controla qué tan rápidamente se adapta el modelo al problema, es uno de los hiperparámetros más importantes en red neuronal. Una tasa de aprendizaje grande significa que la red aprenderá más rápido, y pasos más pequeños significan un aprendizaje más lento.




Figura 1: Dirección del paso (gradiente) y tamaño del paso (taza de aprendizaje)

Se realizaron pruebas con 0.01, 0.005 y 0.001 encontrando que un learning_rate de **0.001** es el adecuado para este modelo.

3.3. Resultados

Se utilizaron 1,100 ejemplos para entrenar el modelo en el conjunto de entrenamiento, al final del entrenamiento se selecciona un elemento al azar en el conjunto de prueba para visualizar la predicción del modelo.

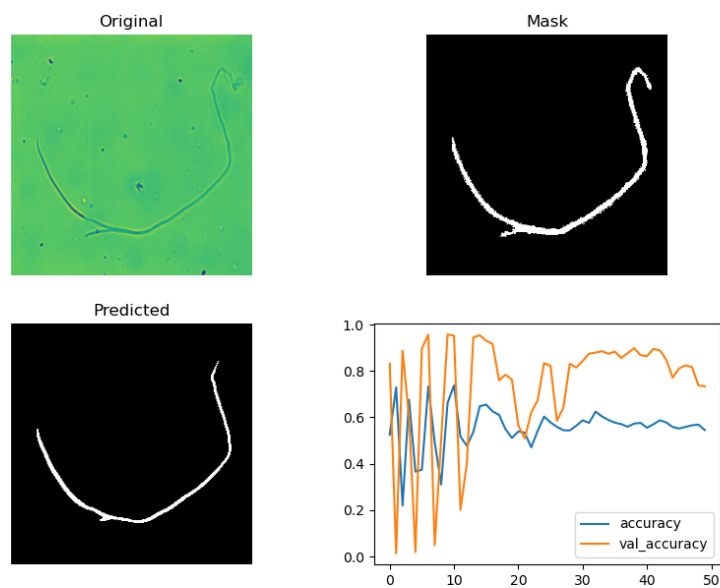


Figura 2: Imagen de entrada, mascar  binaria, predicci n del modelo y gr ficas de precisi n en cada  poca.

Dr. Tapia McClung Horacio
Investigador IIIA
Universidad Veracruzana
htapia@uv.mx



Dra. Candelaria Elizabeth Sansores Pérez
Investigadora Laboratorio de Simulación de Sistemas Complejos
Universidad del Caribe
csansores@ucaribe.edu.mx



Jaime Rangel Ojeda
Estudiante Maestría MIA
Universidad Veracruzana
zs22000513@estudiantes.uv.mx

Referencias

- [Elg20] Mohamed Elgendy. *Deep learning for vision systems*. en. Shelter Island, NY: Manning Publications Co, 2020.